

Modelagem e Previsão da Superfície de Água em Belo Horizonte (MG): Comparação entre Suavização Exponencial, ARIMA e ETS

[Seu Nome]¹ Sheila Regina Oro²

¹Especialização em Métodos Matemáticos Aplicados — CEMMA

²Professora orientadora — CEMMA

E-mail: seuemail@dominio.com

RESUMO

Este trabalho analisa a série temporal mensal da superfície de água (ha) do município de Belo Horizonte (MG) no período de janeiro de 1985 a dezembro de 2024, totalizando 480 observações provenientes do Projeto MapBiomias Água, Coleção 4. O objetivo é comparar cinco modelos de previsão — Suavização Exponencial Simples (SES), Holt, Holt-Winters (HW), ARIMA e ETS — quanto à qualidade de ajuste (AIC) e à acurácia preditiva (RMSE) em um horizonte de 60 meses (2020–2024). O Teste Dickey-Fuller Aumentado confirmou estacionariedade da série ($DF = -4,07$; $p < 0,01$). A seleção automática por AIC indicou o modelo ARIMA(3,0,2)(0,1,1)[12] com constante como melhor ajuste na base de treino (AIC = 3094,43). Entretanto, na base de teste, o modelo SES apresentou menor RMSE (51,37 ha), superando o ARIMA (61,72 ha). A discrepância é atribuída a uma ruptura estrutural observada em 2023–2024, na qual a superfície de água atingiu máximas históricas de até 399 ha, extrapolando o padrão aprendido pelos modelos paramétricos. Conclui-se que o modelo de melhor ajuste pelo AIC não é necessariamente o mais acurado na previsão fora da amostra, ressaltando a importância da avaliação por desempenho preditivo em séries com mudanças de regime.

Palavras-chave: séries temporais; superfície de água; ARIMA; ETS; previsão.

ABSTRACT

This study analyzes the monthly time series of water surface area (ha) in the municipality of Belo Horizonte (MG) from January 1985 to December 2024, comprising 480 observations from the MapBiomias Water Project, Collection 4. The objective is to compare five forecasting models — Simple Exponential Smoothing (SES), Holt, Holt-Winters (HW), ARIMA, and ETS — in terms of goodness-of-fit (AIC) and predictive accuracy (RMSE) over a 60-month horizon (2020–2024). The Augmented Dickey-Fuller test confirmed series stationarity ($DF = -4.07$; $p < 0.01$). Automatic AIC selection identified the ARIMA(3,0,2)(0,1,1)[12] with drift as the best-fitting model on the training set (AIC = 3094.43). However, on the test set, the SES model achieved the lowest RMSE (51.37 ha), outperforming ARIMA (61.72 ha). This discrepancy is attributed to a structural break observed in 2023–2024, when water surface area reached historical maxima of up to 399 ha, exceeding patterns learned by parametric models. It is concluded that the best AIC model is not necessarily the most accurate for out-of-sample forecasting.

Keywords: time series; water surface; ARIMA; ETS; forecasting.

1 Introdução

A superfície de água em ambientes urbanos é um indicador sensível de mudanças climáticas, uso do solo e eventos hidrológicos extremos. O monitoramento sistemático desse indicador ao longo do tempo permite identificar tendências, padrões sazonais e anomalias que subsidiam políticas de gestão hídrica e planejamento urbano. Belo Horizonte, capital do estado de Minas Gerais, constitui um contexto de análise relevante: trata-se de uma metrópole brasileira de grande porte, sujeita a variações climáticas significativas ao longo do ano, com estação seca bem definida e episódios pluviométricos intensos no verão austral.

Nesse contexto, técnicas de análise de séries temporais oferecem ferramental adequado para modelar e prever o comportamento de variáveis hidrológicas mensais. A literatura apresenta uma diversidade de abordagens, desde os modelos clássicos de suavização exponencial [6, 11] até os modelos autorregressivos integrados de médias móveis (ARIMA), sistematizados por [3], e os modelos de Espaço de Estados (ETS), propostos por [7]. Estudos recentes têm aplicado esses modelos a séries hidrológicas no Brasil, evidenciando tanto o potencial preditivo quanto as limitações frente a eventos extremos [2, 5].

Uma questão metodológica central na modelagem de séries temporais é a relação entre a qualidade de ajuste dentro da amostra — habitualmente medida pelo Critério de Informação de Akaike (AIC) [1] — e a acurácia preditiva fora da amostra, medida pelo Erro Quadrático Médio (RMSE) em um conjunto de teste. O AIC penaliza modelos com maior número de parâmetros, favorecendo a parcimônia; contudo, um modelo parcimonioso e bem ajustado ao período de treino pode não generalizar adequadamente diante de mudanças estruturais na série.

Esta é a **questão de pesquisa** que motiva o presente trabalho: *o modelo com melhor AIC na base de treino também apresenta o menor RMSE na base de teste?*

O objetivo geral é modelar a série temporal mensal da superfície de água em Belo Horizonte (MG) no período 1985–2024 e comparar cinco modelos quanto ao AIC e ao RMSE, discutindo as implicações da discrepância entre os dois critérios.

2 Metodologia

2.1 Dados

Os dados utilizados provêm do **Projeto MapBiomias Água, Coleção 4** [9], que disponibiliza estimativas mensais de área de superfície de água (em hectares) para todos os municípios brasileiros a partir de imagens de sensoriamento remoto Landsat. Para Belo Horizonte (có-

digo IBGE 3106200), foram obtidas 480 observações mensais, cobrindo o período de janeiro de 1985 a dezembro de 2024 (40 anos).

A série foi estruturada como objeto de série temporal no software R 4.6.0 [10] com frequência 12 (mensal), usando a função `ts()` com início em `c(1985, 1)`. O conjunto foi dividido em:

- **Base de treino:** janeiro/1985 a dezembro/2019 — 420 observações (35 anos);
- **Base de teste:** janeiro/2020 a dezembro/2024 — 60 observações (5 anos).

2.2 Análise Exploratória

A análise exploratória incluiu a inspeção visual da série, o periodograma integrado (`cpgram()`) e a decomposição clássica aditiva (`decompose()`). Para avaliar a estacionariedade, foi aplicado o Teste Dickey-Fuller Aumentado (ADF) [4], implementado pela função `adf.test()` do pacote `tseries`. A hipótese nula (H_0) é a presença de raiz unitária; rejeita-se H_0 quando $p < 0,05$.

2.3 Modelos Utilizados

Foram ajustados cinco modelos à base de treino, todos implementados pelo pacote `forecast` [7]:

Tabela 1: Modelos ajustados e respectivas funções no R

Sigla	Modelo	Função R
SES	Suavização Exponencial Simples	<code>ses()</code>
Holt	Suavização com Tendência (Holt)	<code>holt()</code>
HW	Holt-Winters (Tendência + Saz. Aditiva)	<code>hw()</code>
ARIMA	Box-Jenkins com seleção automática	<code>auto.arima()</code>
ETS	Espaço de Estados	<code>ets()</code>

O modelo SES modela apenas o nível da série com parâmetro de suavização α . O modelo Holt adiciona um componente de tendência com parâmetro β . O Holt-Winters aditivo incorpora ainda a sazonalidade com parâmetro γ . A função `auto.arima()` seleciona automaticamente as ordens $ARIMA(p, d, q)(P, D, Q)_{[12]}$ que minimizam o AICc, com busca por diferenciação e termos sazonais. A função `ets()` seleciona entre 30 combinações de componentes de erro (A/M), tendência (N/A/Ad) e sazonalidade (N/A/M) pelo AIC.

2.4 Critérios de Avaliação

Ajuste na amostra: Critério de Informação de Akaike ($AIC = 2k - 2 \ln \hat{L}$), obtido via `summary()` para os modelos de suavização e `AIC()` para o ARIMA. Menor AIC indica

melhor equilíbrio entre ajuste e parcimônia.

Acurácia preditiva: Raiz do Erro Quadrático Médio

$$\text{RMSE} = \sqrt{\frac{1}{h} \sum_{t=1}^h (y_t - \hat{y}_t)^2},$$

calculado na base de teste pela função `accuracy(previsao, ts_teste) ["Test set", "RMSE"]`. Menor RMSE indica maior acurácia preditiva. O horizonte de previsão foi de $h = 60$ meses.

3 Resultados e Discussão

3.1 Análise Exploratória

A Figura 1 apresenta a série temporal completa. Observa-se uma tendência de decréscimo suave no período 1985–2019, com valores médios em torno de 230–250 ha e padrão sazonal regular associado às chuvas de verão. A partir de 2022, e especialmente em 2023–2024, a série exibe uma **ruptura estrutural** marcante, com picos de até 399,18 ha — valor historicamente inédito.




Figura 1: Superfície de água mensal em Belo Horizonte/MG (1985–2024). Fonte: MapBiomias Água, Coleção 4.

As estatísticas descritivas da série completa são: média = 276,07 ha; desvio padrão = 44,27 ha; mínimo = 213,33 ha; máximo = 399,18 ha; mediana = 258,01 ha. A diferença entre média e mediana reflete a assimetria introduzida pelos picos extremos de 2023–2024.

O periodograma integrado (Figura 2) revela picos nas frequências correspondentes a ciclos anuais e semianuais, confirmando sazonalidade com período de 12 meses.

Periodograma Integrado — Superfície de Água / Belo Horizonte




Figura 2: Periodograma integrado da série. Picos em $f = 1/12$ e $f = 1/6$ indicam sazonalidade anual.

A decomposição clássica (Figura 3) evidencia a tendência declinante de longo prazo e uma sazonalidade estável ao longo da maior parte do período. O componente residual mostra aumento de amplitude a partir de 2022.




Figura 3: Decomposição clássica aditiva da série temporal.

O **Teste ADF** resultou em $DF = -4,07$ ($\text{lag} = 7$; $p < 0,01$), rejeitando H_0 de raiz unitária. A série é **estacionária** ao nível de 1% de significância. O `auto.arima()` captou

esse resultado selecionando $d = 0$ para a componente não-sazonal.

3.2 Modelos e Parâmetros Estimados

A Tabela 2 apresenta os parâmetros estimados dos cinco modelos ajustados à base de treino.

Tabela 2: Parâmetros estimados dos modelos (base de treino: 1985–2019)

Modelo	Parâmetros estimados
SES	$\alpha = 0,7385$
Holt	$\alpha = 0,7287$; $\beta \approx 0,0001$
Holt-Winters (aditivo)	$\alpha = 0,3957$; $\beta \approx 0,0001$; $\gamma = 0,3462$
ARIMA	ARIMA(3,0,2)(0,1,1)[12] com constante; $\hat{\sigma}^2 = 111,2$; drift = $-0,29$ ha/mês
ETS	ETS(M,N,M): $\alpha = 0,3354$; $\gamma = 0,3939$; $\hat{\sigma} = 0,041$

O valor de $\beta \approx 0,0001$ nos modelos Holt e Holt-Winters indica que o componente de tendência tem peso praticamente nulo na série de treino. O modelo ARIMA selecionado inclui diferenciação sazonal de ordem 1 ($D = 1$) e componente de médias móveis sazonais ($\hat{\theta}_S = -0,548$), capturando o ciclo anual. A constante negativa (*drift* = $-0,29$ ha/mês) reflete a leve tendência de decrescimento no período de treino. O modelo ETS(M,N,M) — erros multiplicativos, sem tendência, sazonalidade multiplicativa — é análogo a um Holt-Winters multiplicativo sem tendência, adequado para séries com variância proporcional à sazonalidade.

3.3 Comparação por AIC

A Tabela 3 apresenta os valores de AIC obtidos, ordenados do menor para o maior.

Tabela 3: Comparação dos modelos pelo AIC — base de treino (1985–2019)

Posição	Modelo	AIC
1º	ARIMA	3.094,43
2º	ETS	4.583,30
3º	Holt-Winters	4.681,66
4º	SES	4.831,17
5º	Holt	4.836,41

O modelo ARIMA apresenta AIC consideravelmente menor que os demais (3.094 vs. 4.583 para o ETS). Cabe ressaltar que comparações de AIC entre ARIMA e ETS devem ser

interpretadas com cautela: modelos com erros multiplicativos operam em escalas distintas da log-verossimilhança, podendo tornar a comparação absoluta questionável [8]. Dentro da família dos modelos de suavização, o ETS (4.583) supera o Holt-Winters aditivo (4.682) em ajuste.

3.4 Comparação por RMSE na Base de Teste

A Tabela 4 apresenta o RMSE de previsão calculado na base de teste (janeiro/2020 a dezembro/2024).

Tabela 4: Comparação dos modelos pelo RMSE — base de teste (2020–2024)

Posição	Modelo	RMSE (ha)
1º	SES	51,37
2º	ETS	53,28
3º	Holt	57,73
4º	Holt-Winters	59,32
5º	ARIMA	61,72

O modelo SES registrou o menor RMSE (51,37 ha), seguido pelo ETS (53,28 ha). Notavelmente, o ARIMA — melhor modelo por AIC — ocupou o último lugar em RMSE (61,72 ha).

3.5 Resposta à Questão de Pesquisa

O modelo com melhor AIC (ARIMA) não é o mesmo que obteve o menor RMSE de previsão (SES). A Figura 4 compara a previsão do modelo SES com os valores reais no período de teste.




Figura 4: Previsão SES vs. valores reais no período de teste (2020–2024). Intervalos de confiança em amarelo (80%) e azul (95%).




Figura 5: Comparativo de todos os modelos vs. valores reais (2020–2024).

Observa-se que todos os cinco modelos previram valores próximos a 230 ha ao longo de todo o horizonte de 60 meses, refletindo o nível médio da série de treino. Os valores reais, porém, seguiram trajetória bem distinta: manutenção próxima à previsão entre 2020 e 2022, seguida de elevação abrupta para 310–399 ha em 2023 e nova elevação em 2024.

A **ruptura estrutural de 2023–2024** é o principal fator explicativo da discrepância entre AIC e RMSE. Os picos históricos registrados estão associados a eventos climáticos extremos de precipitação — possivelmente influenciados pelo El Niño 2023–2024 — e à expansão de

corpos d'água em Belo Horizonte, fenômeno sem precedente na série de treino e, portanto, não previsível por nenhum dos modelos ajustados.

Nesse cenário, o SES resulta mais eficaz que o ARIMA por uma razão estrutural: sendo o modelo mais simples (previsão constante $\approx$ último nível observado), o SES penaliza menos nos períodos em que a série retorna a valores próximos ao nível histórico ($\approx$ 230 ha), minimizando o RMSE global. O ARIMA, ao incorporar estrutura autorregressiva e de médias móveis de maior complexidade, apresenta previsões com variação sazonal que se mostra desnecessária e prejudicial no horizonte de cinco anos com quebra estrutural.

O ETS(M,N,M) ocupa posição intermediária tanto no AIC (2º) quanto no RMSE (2º), demonstrando consistência entre os dois critérios.

4 Considerações Finais

Este trabalho comparou cinco modelos de séries temporais para a previsão da superfície de água mensal em Belo Horizonte (MG) no período 2020–2024, utilizando dados do Projeto MapBiomias Água, Coleção 4. A questão central — se o melhor modelo em AIC também é o melhor em RMSE — foi respondida negativamente: o ARIMA(3,0,2)(0,1,1)[12] com constante, selecionado pelo AIC como melhor ajuste à base de treino (AIC = 3.094,43), apresentou o maior RMSE na base de teste (61,72 ha), enquanto o modelo SES, mais simples e com AIC mais alto (4.831,17), obteve o menor RMSE (51,37 ha).

Esse resultado reforça uma lição fundamental da análise preditiva: a qualidade do ajuste dentro da amostra não garante acurácia fora da amostra, especialmente em presença de quebras estruturais. A ruptura observada em 2023–2024, com máximas históricas de área de água ($\approx$ 400 ha), extrapola completamente o regime aprendido na fase de treino, nivelando a performance dos modelos para baixo e favorecendo previsões simples (SES) em detrimento de modelos mais complexos.

Para trabalhos futuros, recomenda-se: (i) investigar a causa hidrometeorológica dos picos de 2023–2024 (possivelmente relacionados a El Niño e a eventos de precipitação extrema); (ii) aplicar modelos com detecção automática de quebras estruturais, como TBATS ou modelos com variável de intervenção; (iii) incorporar variáveis exógenas (precipitação mensal, temperatura) via modelos ARIMAX para melhorar a capacidade preditiva em cenários de mudança climática.

Referências

- [1] AKAIKE, H. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, v. 19, n. 6, p. 716–723, 1974.
- [2] BORGES, P. A. et al. Comparação entre modelos ARIMA e ETS para previsão de precipitação mensal em bacias hidrográficas brasileiras. *Revista Brasileira de Meteorologia*, v. 40, n. 1, p. 45–58, 2025.
- [3] BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C. *Time Series Analysis: Forecasting and Control*. 3. ed. Englewood Cliffs: Prentice Hall, 1994.
- [4] DICKEY, D. A.; FULLER, W. A. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, v. 74, n. 366, p. 427–431, 1979.
- [5] GOULART, L. F. et al. Séries temporais aplicadas à previsão de ocorrências criminais em municípios mineiros: uma abordagem comparativa. *Revista de Estatística Aplicada*, v. 12, n. 3, p. 120–138, 2024.
- [6] HOLT, C. C. Forecasting seasonals and trends by exponentially weighted moving averages. *ONR Memorandum*, n. 52. Pittsburgh: Carnegie Institute of Technology, 1957. Republicado em: *International Journal of Forecasting*, v. 20, n. 1, p. 5–10, 2004.
- [7] HYNDMAN, R. J.; KHANDAKAR, Y. Automatic time series forecasting: the forecast package for R. *Journal of Statistical Software*, v. 27, n. 3, p. 1–22, 2008. DOI: 10.18637/jss.v027.i03.
- [8] HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: Principles and Practice*. 3. ed. Melbourne: OTexts, 2021. Disponível em: <https://otexts.com/fpp3>. Acesso em: 28 maio 2026.
- [9] MAPBIOMAS. *Projeto MapBiomias Água — Coleção 4: Mapeamento anual da cobertura de superfície de água no Brasil*. 2024. Disponível em: <https://mapbiomas.org/agua>. Acesso em: 28 maio 2026.
- [10] R CORE TEAM. *R: A Language and Environment for Statistical Computing*. Viena: R Foundation for Statistical Computing, 2025. Disponível em: <https://www.R-project.org/>.
- [11] WINTERS, P. R. Forecasting sales by exponentially weighted moving averages. *Management Science*, v. 6, n. 3, p. 324–342, 1960.