



MODELAGEM E PREVISÃO DA SUPERFÍCIE DE ÁGUA EM BELO HORIZONTE (MG): COMPARAÇÃO ENTRE SUAVIZAÇÃO EXPONENCIAL, ARIMA E ETS

Ettore Gabriel Emilio Reis Braga¹
Sheila Regina Oro²

Resumo

Este trabalho analisa a série temporal mensal da superfície de água (ha) do município de Belo Horizonte (MG) no período de janeiro de 1985 a dezembro de 2024, totalizando 480 observações provenientes do Projeto MapBiomas Água, Coleção 4. O objetivo é comparar cinco modelos de previsão: Suavização Exponencial Simples (SES), Holt, Holt-Winters (HW), ARIMA e ETS. E avaliar a qualidade de ajuste (AIC) e medir a acurácia preditiva por meio da métrica de erro quadrático médio (RMSE) em um horizonte de 60 meses (2020–2024). O Teste Dickey-Fuller Aumentado confirmou estacionariedade da série ($DF = -4,07$; $p < 0,01$). A seleção automática por AIC indicou o modelo $ARIMA(3,0,2)(0,1,1)[12]$ com constante como melhor ajuste na base de treino ($AIC = 3094,43$). Entretanto, na base de teste, o modelo SES apresentou menor RMSE (51,37 ha), superando o ARIMA (61,72 ha). A discrepância é atribuída a uma ruptura estrutural observada em 2023–2024, na qual a superfície de água atingiu máximas históricas de até 399 ha, extrapolando o padrão aprendido pelos modelos paramétricos. Conclui-se que o modelo de melhor ajuste pelo AIC não é necessariamente o mais acurado na previsão fora da amostra, ressaltando a importância da avaliação por desempenho preditivo em séries com mudanças de regime.

Palavras-chave: séries temporais; superfície de água; ARIMA; ETS; previsão.

Abstract

This study analyzes the monthly time series of water surface area (ha) in the municipality of Belo Horizonte (MG) from January 1985 to December 2024, comprising 480

observations from the MapBiomas Water Project, Collection 4. The objective is to compare five forecasting models, Simple Exponential Smoothing (SES), Holt, Holt-Winters (HW), ARIMA, and ETS in terms of goodness-of-fit (AIC) and predictive accuracy (RMSE) over a 60-month horizon (2020–2024). The Augmented Dickey-Fuller test confirmed series stationarity ($DF = -4.07$; $p < 0.01$). Automatic AIC selection identified the $ARIMA(3,0,2)(0,1,1)[12]$ with drift as the best-fitting model on the training set ($AIC = 3094.43$). However, on the test set, the SES model achieved the lowest RMSE (51.37 ha), outperforming ARIMA (61.72 ha). This discrepancy is attributed to a structural break observed in 2023–2024, when water surface area reached historical maxima of up to 399 ha, exceeding patterns learned by parametric models. It is concluded that the best AIC model is not necessarily the most accurate for out-of-sample forecasting.

Keywords: time series; water surface; ARIMA; ETS; forecasting.

Introdução

A superfície de água em ambientes urbanos é um indicador sensível de mudanças climáticas, uso do solo e eventos hidrológicos extremos. O monitoramento sistemático desse indicador ao longo do tempo permite identificar tendências, padrões sazonais e anomalias que subsidiam políticas de gestão hídrica e planejamento urbano. Belo Horizonte, capital do estado de Minas Gerais, constitui um contexto de análise relevante: trata-se de uma metrópole brasileira de grande porte, sujeita a variações climáticas significativas ao longo do ano, com estação seca bem definida e episódios pluviométricos intensos no verão.

Nesse contexto, técnicas de análise de séries temporais oferecem ferramentas adequadas para modelar e prever o comportamento de variáveis hidrológicas mensais. A literatura apresenta uma diversidade de abordagens, desde os modelos clássicos de suavização exponencial (HOLT, 1957; WINTERS, 1960) até os modelos autorregressivos integrados de médias móveis (ARIMA), sistematizados por Box, Jenkins e Reinsel (1994), e os modelos de Espaço de Estados (ETS), discutidos por Hyndman e Khandakar (2008). Estudos recentes têm aplicado esses modelos a séries hidrológicas no Brasil, evidenciando tanto o potencial preditivo quanto as limitações frente a eventos extremos (LUCAS, EDMUNDO et al., 2009; CAMINHA, A. R. et al., 2025).

Uma questão metodológica central na modelagem de séries temporais é a relação entre a qualidade de ajuste dentro da amostra — habitualmente medida pelo Critério de Informação de Akaike (AIC) (AKAIKE, 1974) — e a acurácia preditiva fora da amostra, medida pelo Erro Quadrático Médio (RMSE) em um conjunto de teste. O AIC penaliza modelos com maior número de parâmetros, favorecendo a parcimônia; contudo, um modelo conservador e bem ajustado ao período de treino pode não generalizar adequadamente diante de mudanças estruturais na série.

Esta é a **questão de pesquisa** que motiva o presente trabalho: *o modelo com melhor AIC na base de treino também apresenta o menor RMSE na base de teste?*

O objetivo geral é modelar a série temporal mensal da superfície de água em Belo Horizonte (MG) no período de 1985 a 2024 e comparar cinco modelos quanto ao AIC e ao RMSE, discutindo as implicações da discrepância entre os dois critérios.

Metodologia

Dados

Os dados utilizados provêm do Projeto MapBiomias Água, Coleção 4 (MAPBIOMAS, 2024), que disponibiliza estimativas mensais de área de superfície de água (em hectares) para todos os municípios brasileiros a partir de imagens de sensoriamento remoto Landsat. Para Belo Horizonte (código IBGE 3106200), foram obtidas 480 observações mensais, cobrindo o período de janeiro de 1985 a dezembro de 2024.

A série foi estruturada como objeto de série temporal no software R (R CORE TEAM, 2025) com frequência 12 (mensal). O conjunto foi dividido em base de treino e base de testes com as seguintes configurações:

- **Conjunto de Treino:** de janeiro de 1985 a dezembro de 2019, totalizando 420 observações (35 anos);
- **Conjunto de Teste:** de janeiro de 2020 a dezembro de 2024, totalizando 60 observações (5 anos).

Análise Exploratória

A análise exploratória incluiu a inspeção visual da série, o periodograma integrado e a decomposição clássica aditiva. Para avaliar a estacionariedade, foi aplicado o Teste

Dickey-Fuller Aumentado (DICKEY; FULLER, 1979). A hipótese nula (H_0) é a presença de raiz unitária; rejeita-se essa hipótese quando $p < 0,05$.

Modelos Utilizados

Foram ajustados cinco modelos à base de treino, todos implementados pelo pacote forecast do R (HYNDMAN; KHANDAKAR, 2008): Suavização Exponencial Simples (SES), Holt, Holt-Winters, ARIMA e ETS.

Tabela 1. Modelos ajustados e respectivas funções no R

Sigla	Modelo	Função R
SES	Suavização Exponencial Simples	ses()
Holt	Suavização com Tendência (Holt)	holt()
HW	Holt-Winters (Tendência + Sazonalidade Aditiva)	hw()
ARIMA	Box-Jenkins com seleção automática	auto.arima()
ETS	Espaço de Estados	ets()

Fonte: Autoria própria (2026)

O modelo SES modela apenas o nível da série com parâmetro de suavização α . O modelo Holt adiciona um componente de tendência com parâmetro β . O Holt-Winters aditivo incorpora ainda a sazonalidade com parâmetro γ . A função auto.arima() seleciona automaticamente as ordens do modelo ARIMA que minimizam o AICc, considerando diferenciação e termos sazonais. A função ets() seleciona automaticamente combinações de componentes de erro, tendência e sazonalidade pelo AIC.

Critérios de Avaliação

Ajuste na amostra: foi utilizado o Critério de Informação de Akaike (AIC), em que menores valores indicam melhor equilíbrio entre ajuste e parcimônia.

$$AIC = 2k - 2\ln\hat{L}$$

Acurácia preditiva: foi utilizada a Raiz do Erro Quadrático Médio (RMSE), calculada na base de teste. Menores valores de RMSE indicam maior acurácia preditiva. O horizonte de previsão considerado foi de 60 meses.


$$RMSE = \sqrt{\frac{1}{h} \sum_{t=1}^h (y_t - \hat{y}_t)^2}$$

Resultados e Discussão

Análise Exploratória

A figura 1 apresenta a serie temporal completa e pode-se observar uma tendência de decrescimento suave no período de 1985 a 2019, com valores médios em torno de 230 a 250 ha e padrão sazonal regular associado às chuvas de verão. A partir de 2022, e especialmente em 2023 e 2024, a série exibe uma **ruptura estrutural** marcante, com picos de até 399,18 ha, valor historicamente inédito.

Figura 1: Superfícies de água mensal em Belo Horizonte



Fonte: Autoria própria (2026)


As estatísticas descritivas da série temporal completa são: média = 276,07 ha; desvio padrão = 44,27 ha; mínimo = 213,33 ha; máximo = 399,18 ha; mediana = 258,01 ha. A

diferença entre média e mediana reflete a assimetria introduzida pelos picos extremos de 2023 e 2024.

O periodograma integrado, apresentado pela figura 2, revela picos nas frequências correspondentes a ciclos anuais e semianuais, confirmando sazonalidade com período de 12 meses.

Figura 2: Periodograma integrado da série temporal

Periodograma Integrado — Superfície de Água / Belo Horizonte




Fonte: Autoria própria (2026)

A decomposição clássica, apresentado no gráfico da figura 3, evidencia a tendência declinante de longo prazo e uma sazonalidade estável ao longo da maior parte do período. O componente residual mostra aumento de amplitude a partir de 2022.

O Teste ADF resultou em $DF = -4,07$ ($\text{lag} = 7$; $p < 0,01$), rejeitando a hipótese nula de raiz unitária. A série é, portanto, estacionária ao nível de 1% de significância. A função de *auto.arima()* aplicada captou esse resultado selecionando $d = 0$ para a componente não sazonal.

Figura 3: Decomposição da série Temporal



Fonte: Autoria própria (2026)

Modelos e Parâmetros Estimados

A Tabela 2 apresenta os parâmetros estimados dos cinco modelos ajustados à base de treino.

Tabela 2. Parâmetros estimados dos modelos (base de treino: 1985–2019)

Modelo	Parâmetros estimados
SES	$\alpha = 0,7385$
Holt	$\alpha = 0,7287$; $\beta \approx 0,0001$
Holt-Winters (aditivo)	$\alpha = 0,3957$; $\beta \approx 0,0001$; $\gamma = 0,3462$
ARIMA	ARIMA(3,0,2)(0,1,1)[12] com constante; $\sigma^2 = 111,2$; drift = -0,29 ha/mês

ETS	ETS(M,N,M): $\alpha = 0,3354$; $\gamma = 0,3939$; $\sigma = 0,041$
-----	--

Fonte: Autoria própria (2026)

O valor de β praticamente nulo nos modelos Holt e Holt-Winters indica que o componente de tendência tem peso muito reduzido na série de treino. O modelo ARIMA selecionado inclui diferenciação sazonal de ordem 1 e componente sazonal de médias móveis, capturando o ciclo anual. Já o modelo ETS(M,N,M) é compatível com uma estrutura sem tendência e sazonalidade multiplicativa.

Comparação por AIC

A Tabela 3 apresenta os valores de AIC obtidos, ordenados do menor para o maior.

Tabela 3. Comparação dos modelos pelo AIC — base de treino (1985–2019)

Posição	Modelo	AIC
1º	ARIMA	3.094,43
2º	ETS	4.583,30
3º	Holt-Winters	4.681,66
4º	SES	4.831,17
5º	Holt	4.836,41

Fonte: Autoria própria (2026)

O modelo ARIMA apresentou AIC de 3094,43 que é consideravelmente menor que os demais, indicando melhor ajuste na base de treino. Dentro da família dos modelos de suavização, o ETS superou o Holt-Winters aditivo em termos de ajuste. Segundo (HYNDMAN; KHANDAKAR, 2008), é importante ressaltar que comparações de AIC entre ARIMA e ETS devem ser interpretadas com cautela pois modelos com erros multiplicativos operam em escalas distintas da log-verossimilhança, podendo tornar a comparação absoluta questionável.

Comparação por RMSE na Base de Teste

A Tabela 4 apresenta o RMSE de previsão calculado na base de teste, correspondente ao período de janeiro de 2020 a dezembro de 2024.

Tabela 4. Comparação dos modelos pelo RMSE — base de teste (2020–2024)

Posição	Modelo	RMSE (ha)
1º	SES	51,37
2º	ETS	53,28
3º	Holt	57,73
4º	Holt-Winters	59,32
5º	ARIMA	61,72


Fonte: Autoria própria (2026)

O modelo SES registrou o menor RMSE (51,37 ha), seguido pelo ETS (53,28 ha). Notavelmente, o ARIMA (melhor modelo por AIC) ocupou o último lugar em RMSE (61,72 ha).

Resposta à Questão de Pesquisa


O modelo com melhor AIC (ARIMA) não foi o mesmo que apresentou o menor RMSE de previsão (SES). A Figura 4 compara a previsão do modelo SES com os valores reais no período de teste. Observa-se que todos os cinco modelos previram valores próximos ao nível médio da série de treino ao longo do horizonte de 60 meses. Contudo, os valores reais seguiram trajetória distinta, com elevação abrupta em 2023 e 2024.

Figura 4: Previsão SES versus valores reais no período de teste (2020–2024)



Fonte: Autoria própria (2026)

Figura 5: Comparativo de todos os modelos versus valores reais (2020–2024)



Fonte: Autoria própria (2026)

A ruptura estrutural observada em 2023 e 2024 é o principal fator explicativo da discrepância entre AIC e RMSE. Os picos históricos registrados extrapolam o regime aprendido pelos modelos na fase de treino. Nesse cenário, o SES mostrou-se mais eficaz por sua simplicidade estrutural, enquanto o ARIMA, embora superior em ajuste na amostra, apresentou menor capacidade de generalização fora da amostra.

Considerações Finais

Este trabalho comparou cinco modelos de séries temporais para a previsão da superfície de água mensal em Belo Horizonte (MG) no período de 2020 a 2024, utilizando dados do Projeto MapBiomass Água, Coleção 4. A questão central, se o melhor modelo em AIC também seria o melhor em RMSE, foi respondida negativamente: o ARIMA(3,0,2)(0,1,1)[12] com constante, selecionado pelo AIC como melhor ajuste à base de treino (AIC = 3094,43), apresentou o maior RMSE na base de teste (61,72 ha), enquanto o modelo SES, mais simples, obteve o menor RMSE (51,37 ha).

Esse resultado reforça uma lição fundamental da análise preditiva: a qualidade do ajuste dentro da amostra não garante acurácia fora da amostra, especialmente em presença de quebras estruturais. Para trabalhos futuros, recomenda-se investigar as causas hidrometeorológicas dos picos observados em 2023 e 2024, aplicar modelos com detecção automática de quebras estruturais e incorporar variáveis como precipitação e temperatura, em modelos mais robustos.

Referências

AKAIKE, H. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, v. 19, n. 6, p. 716-723, 1974.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C. *Time series analysis: forecasting and control*. 3. ed. Englewood Cliffs: Prentice Hall, 1994.

CAMINHA, A. R., Guimarães, L. R., Corrêa, F. V., Souza, G. R. de, Oliveira, L. F. C. de, & Sáfiadi, T. (2025). Previsão de precipitação e vazão a partir da modelagem de séries temporais. *Revista Brasileira De Climatologia*, 36(21), 264–290. <https://doi.org/10.55761/abclima.v36i21.18885>.

DICKEY, D. A.; FULLER, W. A. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, v. 74, n. 366, p. 427-431, 1979.

HOLT, C. C. Forecasting seasonals and trends by exponentially weighted moving averages. *ONR Memorandum*, n. 52. Pittsburgh: Carnegie Institute of Technology, 1957.

HYNDMAN, R. J.; KHANDAKAR, Y. Automatic time series forecasting: the forecast package for R. *Journal of Statistical Software*, v. 27, n. 3, p. 1-22, 2008. DOI: 10.18637/jss.v027.i03.

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021. Disponível em: <https://otexts.com/fpp3>. Acesso em: 28 maio 2026.

MAPBIOMAS. *Projeto MapBiomias Água - Coleção 4: mapeamento anual da cobertura de superfície de água no Brasil*. 2024. Disponível em: mapbiomas.org/agua. Acesso em: 28 maio 2026.

LUCAS, EDMUNDO & Sousa, Francisco & Daniel, Fabricio & Lucio, Paulo. (2009). Modelagem hidrológica determinística e estocástica aplicada à região hidrográfica do Xingu- Pará. *Revista Brasileira de Meteorologia*. 24. 308-322. 10.1590/S0102-77862009000300005.

R CORE TEAM. *R: a language and environment for statistical computing*. Viena: R Foundation for Statistical Computing, 2025. Disponível em: www.R-project.org/. Acesso em: 28 maio 2026.